

GROKking

grokking 튜닝 — 8변형 전부 회상 학습 + 아키텍처별 용량 천장

결론: 8변형 모두 MQAR 연관회상을 학습한다(>chance). 단 정확회상($near-1.0$)을 grok하는 난이도는 아키텍처 메커니즘에 따라 크게 다르다. softmax·영속메모리·게이팅·(감쇠+용량)이 있으면 다중키 회상을 grok하고, **순수 선형 어텐션(감쇠·게이트·선택 전무)**은 다중키에서 천장(~0.5)에 갇힌다.

검증 환경: RTX 4090, 실학습. 도구: `grok_tune.py`. 과제: MQAR(vocab32). 지표: query 위치 recall. grokking 가속 레버(Power et al.): weight decay · 충분한 스텝 · warmup/cosine · (선형계열) 상태 용량.

종합 결과 (2키 회상, chance≈0.062)

변형	최고 recall	grok 점프	그것을 가능케 한 것
swla_residual	1.00	step 2k	softmax 어텐션
titans_ssc	1.00	4k	영속메모리 + top_k 선택
linear_grm	0.93	5.5k	head 게이팅
dla_residual	1.00	8k	데이터 의존 감쇠 + 상태 용량↑(dh=128)
titans_residual	1.00	13k	영속메모리(느리지만 grok)
linear_ssc	0.58	~20k 진행형	top_k 선택(매우 느림)
linear_residual	0.54 (2키 천장)	없음	— (순수 선형)
linear_soup	0.50 (2키 천장)	없음	— (순수 선형)

1키 회상(자명)에서는 전부 1.0

`linear_residual` · `linear_soup` 도 pairs=1에서는 즉시 1.0(step 1k). → 회상 자체는 학습 가능하며, 막히는 것은 다중키 정확회상 용량이다. 천장은 "2키 중 1키만 안정 회상"(=0.5)으로 나타난다.

긴 컨텍스트(seq=512, 16×)에서도 titans는 1.0 grok ★

titans_residual을 seq=512(16× 긴 컨텍스트), dh=128, chunked, 25k 스텝으로 학습: recall 1.0(hard 0.62), grok@15000 (step14k까지 0.33 정체 → 0.60→0.79→0.94→1.0 급점프). → 긴 컨텍스트에서도 완벽 회상 + 추론 O(1) 상수메모리 동시 달성. 대가는 학습 컴퓨트(LONGSEQ.md).

시도한 레버와 효과

레버	효과
쉬운 과제(pairs 8→4→2)	약한 변형도 학습 시작(부분해 0.34→0.53)
스텝 ↑ (6k→20k)	titans_residual을 13k에서 grok시킴
weight decay ↑ (0.1→0.5)	순수 선형엔 무효(천장 불변)
상태 용량 ↑ (head 8→2, dh 32→128, 상태 16×)	dla_residual을 grok시킴(선형 어텐션 회상 용량 ∝ 상태 크기 입증)

해석 (AutoResearch 관점)

이것이 본 노드의 존재 이유를 정확히 보여준다 — "이 데이터의 회상 난이도에 맞는 (표현→기억) 구성"을 자동 탐색:

- 회상 요구가 크면 → softmax(swla)/영속메모리(titans)/게이팅(grm)/감쇠+큰상태(dla, head↓) 선택.
- 순수 선형(linear+residual/soup)은 효율은 최고지만 다중기 정확회상엔 부적합 → 효율↔정확도 트레이드오프.
- 이 천장은 선형 어텐션의 알려진 MQAR 한계(Zoology)와 일치. 스텝·wd로는 못 뚫고 **용량**이 유효 레버.

재현

```
python3 grok_tune.py --variants all --steps 8000 --wd 0.1 --pairs 2 --vocab 32 --
seq-len 16
python3 grok_tune.py --variants dla_residual --steps 12000 --pairs 2 --n-heads 2 #
용량↑로 grok
python3 grok_tune.py --variants linear_residual,linear_soup --pairs 1 #
1키는 전부 1.0
```