

IMPACT

영향 분석 — 하드웨어 비용 절감과 가능해지는 것

메모리캐싱(선형/Titans, chunked 학습 + 재귀 추론)이 어디서 얼마나 비용을 아끼고, 그 위에서 무엇을 할 수 있는지. 모든 수치는 본 저장소 4090 실측(COMPARE3/INFERENCE/LONGSEQ.md) 기반.

핵심 범위: 이건 모든 LLM을 싸게가 아니라 긴 컨텍스트 추론 + 온프레미스/엣지에서 압도적. 대가는 정확회상 품질(선형이 softmax보다 약함, GROKING.md) → 그래서 AutoResearch로 데이터별 효율↔정확도 균형을 탐색한다.

1. 무엇이 선형/상수가 되는가 (실측 요약)

측	트랜스포머	선형/Titans(우리)
학습 메모리	O(L) (FlashAttn)	O(L) (chunked) — 동급
학습 연산	O(L ²)	O(L) — 128K에서 3× 빠름(실측)
추론 메모리	O(L) KV캐시(무한 증가)	O(1) 132KB 상수
추론 연산/토큰	O(L)	O(1)

2. 하드웨어 비용 절감 (같은 컨텍스트 KV 용량, 대략 시세)

KV캐시 8KB/토큰(소형 모델 실측). 선형은 1×4090에서 모든 길이 26MB.

컨텍스트	선형: 1×4090(~\$2K)	트랜스포머 필요	절감
2M	\$2K	1×4090(한계)	—
16M	\$2K	2× A100-80G (~\$36K)	~18×
64M	\$2K	7× A100 (~\$126K)	~63×
256M	\$2K	26× A100 (~\$468K)	~230×

운영비(클라우드): A100 24/7 ≈ 17.5K/년/장 → 7장** 122K/년** vs 4090 1대 소유(~2K + 전기/0.5K/년) = 연 60배 + 차이. 컨텍스트가 길수록 절감 배수↑.

단서: 추론 KV/메모리 병목 축의 비교다. 트랜스포머 클러스터는 모델·연산 용량도 주므로 1:1 동급 아님. GQA/MQA·paged-attention·fp16이 KV를 줄여 격차를 완화하나 여전히 O(L) — O(1)은 선형/Titans뿐.

3. 이걸 기반으로 할 수 있는 효과

1. 온프레미스 AutoResearch — 클라우드 0원: 단일 4090으로 설계공간 자동 탐색(본 노드의 KPI: 싸게 많이 시도). 클러스터 임대 불필요 → 연 수만~수십만 달러 절감.
2. 엣지 무한 스트리밍 추론(24/7): 상태 132KB 상수 → 라즈베리파이급에서 끊임 없이 무한 길이 센서 스트림 추론 (HC-SR04 이상탐지). 트랜스포머는 KV 누적으로 결국 OOM.
3. 데이터 주권: 민감 제조 데이터를 클라우드로 안 보내고 현장에서 학습·추론(규제·보안).
4. 긴 컨텍스트를 소비자 HW에서: 수개월치 로그·전체 장비 이력을 한 컨텍스트로 — 데이터센터 없이.
5. 길수록 벌어지는 우위: 16M 18× → 256M 230×. 장기 모니터링·평생 메모리 에이전트에 특히 유리.

4. 성능(품질)도 그만큼 좋은가? — 아니오, 비대칭이다 (정직)

하드웨어 절감은 크지만 정확도가 같이 따라오진 않는다. 단, 미묘하다(GROKING.md 실측):

변형	추론 메모리	2키 회상 정확도
순수 linear (메모리 최선)	O(1) 132KB	0.5 (천장, 약함)
dla	O(1) 132KB	1.0 (용량↑ 필요)
titans (짧은 ctx)	O(1) 132KB	1.0 (13k스텝)
titans (긴 ctx seq=512)	O(1) 132KB	1.0 (grok@15k, 실측)
트랜스포머(softmax)	O(L) KV	1.0 (가장 쉽게/빨리 학습)

핵심:

- 메모리 절감은 재귀 계열(linear/dla/titans) 전부 동일(O(1) 132KB).
- 품질은 계열 안에서 크게 다름 — 가장 싼 순수 linear가 가장 약함(0.5). 그러나 titans는 같은 O(1) 상수메모리로 정확도 1.0 달성 → "상수메모리 = 저품질"은 아님.
- 대가는 메모리가 아니라 학습 비용/난이도: titans는 1.0 도달에 ~13k스텝(softmax 2k)·용량 필요.
- 트랜스포머(softmax)는 회상 정확도를 가장 쉽게 얻지만 추론 메모리 O(L).

→ 즉 "공짜 점심"은 아니다. 추론 하드웨어 비용 수십~수백배 절감은 사실이나, 동급 정확도를 얻으려면 (a) 적절한 변형 (titans 등) 선택 + (b) 더 많은 학습 컴퓨트가 필요. 이 균형점을 데이터별로 찾는 것이 AutoResearch 노드의 존재 이유.

실증(긴 컨텍스트): titans를 seq=512(16× 긴 컨텍스트)에서 25k 스텝 학습 → recall 1.0(grok@15k), 추론은 여전히 O(1) 132KB 상수. 즉 정확도 1.0과 상수메모리 추론을 동시에 얻을 수 있고, 비용은 학습 컴퓨트(일회성)로 치른다. (LONGSEQ.md)

한 줄

긴 컨텍스트 추론을 데이터센터 GPU 클러스터 대신 단일 소비자 GPU/엣지에서 상수 메모리로 — 컨텍스트가 길수록 수십~수백 배 하드웨어 비용을 아낀다. 대가는 정확회상 품질이며, 그 균형을 찾는 것이 AutoResearch 노드의 존재 이유다.

근거 문서

[COMPARE3.md](#) 3자 메모리·시간 · [INFERENCE.md](#) KV캐시·하드웨어 환산 · [LONGSEQ.md](#) 긴 시퀀스 학습 · [GROKING.md](#) 정확도 트레이드오프 · [RECURRENT.md](#) 재귀 동치