

INFERENCE

추론 메모리 — 트랜스포머 KV캐시 vs 선형 재귀상태 (4090 실측)

자기회귀 추론에서 컨텍스트 길이별 메모리. 동일 소형 모델(d256/L4/h8). 재현: `infer_bench.py`.

실측 (4090, fp32)

컨텍스트 L	트랜스포머 KV캐시	선형 재귀(우리)
8,192	0.08 GB	25.9 MB
131,072	1.17 GB	25.9 MB
1,048,576 (1M)	9.69 GB	25.9 MB
2,097,152 (2M)	19.35 GB	25.9 MB
4,194,304 (4M)	OOM	25.9 MB

- 트랜스포머 KV캐시 = $O(L)(8KB/토큰) \rightarrow$ 4090에서 ~2.4M 토큰 한계(4M OOM).
- 선형 재귀 상태 = 132KB 상수(추론 peak 25.9MB, L 무관) $\rightarrow$ 사실상 무한 컨텍스트.

"1×4090 + 선형" $\approx$ 트랜스포머로는 어느 정도 하드웨어?

선형은 1×4090에서 모든 길이를 26MB로 처리. 같은 컨텍스트를 트랜스포머 KV캐시로 감당하려면:

목표 컨텍스트	선형 on 1×4090	TF KV캐시	$\approx$ 트랜스포머 하드웨어
2M	26 MB	19 GB	1× 4090(한계)
16M	26 MB	128 GB	$\sim 6\times 4090$ / $2\times A100-80G$
64M	26 MB	512 GB	$\sim 22\times 4090$ / $7\times A100-80G$
256M	26 MB	2 TB	$\sim 90\times 4090$ / $26\times A100-80G$
∞	26 MB	∞	유한 GPU 불가

$\rightarrow$ 컨텍스트가 길수록 1×4090+선형이 대체하는 트랜스포머 KV 하드웨어가 무한히 커진다.

정직한 단서

- 추론 KV캐시 메모리 비교(+선형은 토큰당 연산도 $O(1)$ 이라 더 빠름; COMPARE3.md 시간 벤치).

- 실 LLM은 GQA/MQA·paged-attention·fp16으로 KV를 줄여 격차 완화 — 단 여전히 $O(L)$. $O(1)$ 은 선형/Titans
뿐.
- 소형 모델 절대 길이이며, 큰 모델이면 길이는 줄지만 상수 vs $O(L)$ 비율은 동일.