

LONGSEQ

긴 시퀀스 학습 — chunked O(L)로 OOM 없이

naive 병렬($O(L^2)$)으로는 불가능하던 긴 컨텍스트 학습을 **chunked linear attention($O(L)$)**으로 가능케 함. 학습 경로(`grok_tune.py --chunked` , `model.forward_chunked(return_aux=True)`)를 chunked로 전환. 4090 실측.

1. 학습 메모리 — chunked가 길수록 압도적 (forward+backward, MQAR)

seq_len	naive 학습 peak	chunked 학습 peak	비고
2048 (B=8,h=2)	4026 MB	2261 MB (~1.8× 적음)	둘 다 가능(소배치)
8192 (forward)	8827 MB	220 MB (~40×)	격차가 길어로 확대
16384 (forward)	OOM	321 MB	naive 불가

→ 길이가 길수록 naive는 $O(L^2)$ 로 폭증/OOM, chunked는 $O(L)$. **긴 시퀀스 학습은 chunked라야 가능.**

1b. 4090 최대 학습 seq_len (batch=1, d256/L4/h2, chunk=256)

seq_len	peak	step
32768	4.14 GB	0.5s
65536	8.21 GB	1.6s
131072 (128K)	16.32 GB	5.4s ← 최대
262144 (256K)	OOM	—

완벽한 $O(L)$: 길이 2× → 메모리 2×(≈0.125MB/토큰). **단일 4090에서 128K 토큰 컨텍스트 학습 가능** (naive $O(L^2)$ 면 16384에서 OOM → chunked로 8×+ 더 길게). 재현: `maxseq.py` .

2. 긴 컨텍스트 MQAR 학습 결과 (kv 앞쪽, query 말단, 사이 수백~수천 pad)

설정	변형	final recall	hard	학습시간	OOM
seq=512, pairs=4, h=2	linear	0.348	0.264	126s/5k	✅ 없음
seq=512	dla	0.327	0.267	152s/5k	✅ 없음
seq=512	titans	0.340	0.269	157s/5k	✅ 없음
seq=2048, pairs=4	linear	0.349	0.267	112s/2k	✅ 없음

chance≈0.062. 위는 5k 스텝 기준 ~0.35 부분해. **충분히 학습하면 grok한다(아래).**

titans 긴 컨텍스트 정확도 끌어올리기 (dh=128, chunked, 25k 스텝) ☆

설정	변형	final recall	grok@	학습시간
seq=512, pairs=4, h=2	titans_residual	1.00 (hard 0.62)	15000	792s

곡선: ~step14000까지 0.33 정체 → **15000에서 급점프**(0.60→0.79→0.94→0.99→**1.0**). → **16× 긴 컨텍스트 (seq=512)에서 완벽 회상(1.0) + 추론 O(1) 상수메모리(132KB)**. 대가는 학습 컴퓨트 (grok@15k)뿐. "상수메모리 = 저 품질"이 아님을 긴 컨텍스트에서 실증(IMPACT.md §4).

3. 해석 (정직)

-  **엔지니어링 목표 달성:** seq=32(초기) → **2048(64×)** 컨텍스트를 OOM 없이 학습. chunked가 핵심.
-  **회상 품질은 부분해:** 긴 컨텍스트 다중키 정확회상은 5k 스텝 내 grok 점프 안 함. 원인: (a) 선형/감쇠 계열의 다중키 회상 한계(GROKING.md), (b) 긴 pad gap이 회상 난이도↑, (c) dla/titans는 감쇠가 장거리 신호를 약화(floor 0.9라도 수천 스텝 누적 시 감쇠). → 더 많은 스텝·용량(dh↑)·낮은 감쇠가 필요(후속). swla(softmax)는 chunked 비대상(원도우).

결론

"더 긴 시퀀스 학습"은 가능해졌다 — chunked O(L)로 64× 긴 컨텍스트를 OOM 없이 학습(메모리 1.8~40× 절감). 회상 품질의 grok은 추가 컴퓨트가 필요(데이터 규모/예산 의존) — 정직한 현 상태.

재현

```
python3 grok_tune.py --chunked --seq-len 2048 --pairs 4 --batch 8 --n-heads 2 \
  --variants linear_residual --steps 2000
```